SVM - Метод опорных векторов

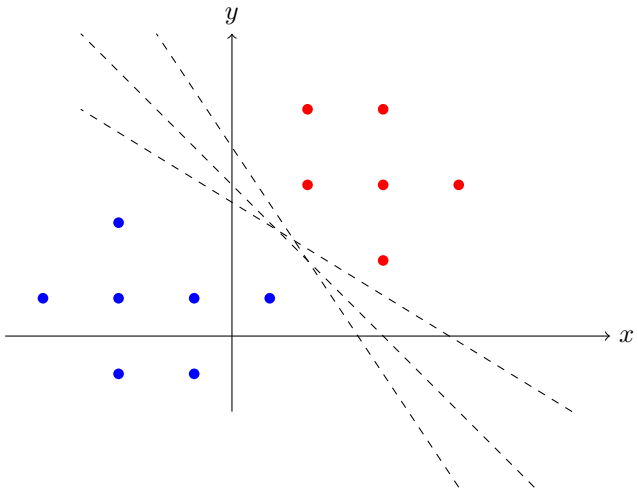
Darkhan Nurlybay

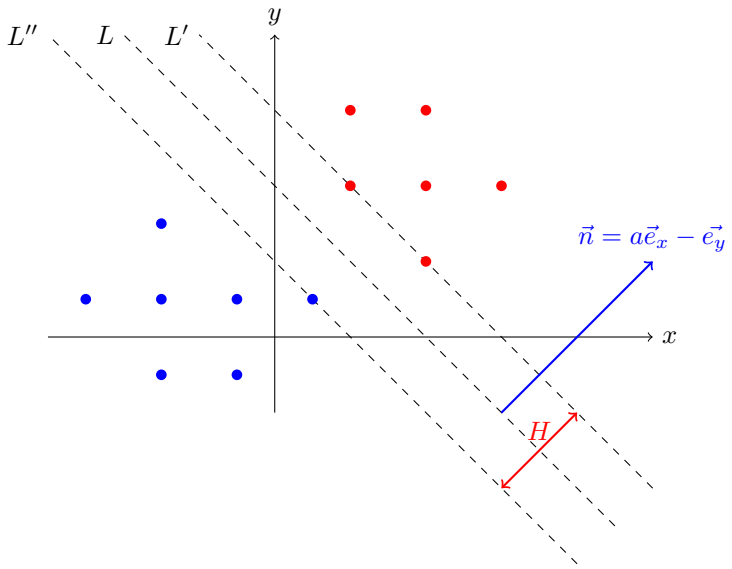
October 2024

1 Introduction

Часто в алгоритмах машинного обучения возникает необходимость классифицировать данные. В данной задаче надо реализовать **метод опорных векторов** (support vector machine – SVM), который относится к семейству линейных классификаторов.

Для простоты рассмотрим n точек в двумерном пространстве. Каждая из этих точек принадлежит только одному из двух классов: $l_i = \pm 1$. Гарантируется, что точки можно разделить так, что в одной стороне линий будут находится точки одного класса. Искомых линей может быть много, поэтому будем находить такую линую, что сумма расстояний до линей L от двух ближайших к ней точек, лежащих по разные стороны от неё, максимальна. Это способствует более уверенной классификации. Для удобство линий L' и L'' которые проходят через эти две точки будем называт опорными векторами.





Пусть линия L задется уравнием $y = ax+b$, тогда L' и L'' можно описать $y = ax + b + \delta$ и $y = ax + b - \delta = 0$ соответсвенно. Нетрудно показать, что расстояние между L' и L'' равно:

$$H = \frac{2\delta}{|\vec{n}|} \tag{1}$$

Точку (x, y) будем классифицировать сделующим образом:

$$a(x, y) = \begin{cases} +1, \text{ если } y \geq ax + b \\ -1, \text{ иначе} \end{cases} \tag{2}$$

Алгоритм будем штрафовать при непривилной классификации:

$$f(x, y, l) = \begin{cases} 0, \text{ если } a(x, y) = l \\ |\vec{n}|^2 \, d(L, x, y), \text{ иначе} \end{cases} \tag{3}$$

Тут $d(L, x, y)$ - расстояние точки (x, y) до линии L.

Также мы ходим, чтобы зазор между опорными векторами L' L'' был как можно большим, поэтому рассмотрим фукнцию потерь (λ будет задан):

$$Loss = \lambda|\vec{n}|^2 + \frac{1}{n}\sum_{i=1}^{n} f(x_i, y_i, l_i); \tag{4}$$

Ваша цель найти параметры a, b линии L через градиенты спуск, который будет минимизировать $Loss$.

В контесте будем измерять для каждого теста долю правильных ответов (точность) и итоговая оценка будет минимальная из них умноженная на 100.